ANN Lab2 Report

何秉翔 计04 2020010944

0. 前言

Lab2 实验主要使用 `PyTorch` 框架对 `CNN` 和 `MLP` 进行搭建，并手动实现 `BatchNorm` 和 `Dropout`，完成 `cifar-10 classification` 的分类任务，目的在于学会使用深度学习框架去搭建更深的网络架构。

1. `MLP`

1.1 网络架构

我们采用文档中给出的 `input -- Linear - BN - ReLU - Dropout - Linear - loss` 的架构进行搭建网络，实验中设置的超参数如下：

```
{
    "dropout_rate": [0.0, 0.1, 0.3, 0.5],          (可改变)
    "batch_size": [50, 100, 200, 500],             (可改变)
    "learning_rate": [0.01, 0.001, 0.0005, 0.0001], (可改变)
    "num_epochs": 50,
    "hidden_size": 1024,
}
```

其中，`hidden_size` 为 `MLP` 网络隐藏层维度，我们固定为 1024，固定跑 50 个 `epoch`，网络架构如下：

```
Model(

  (network): Sequential(
    (0): Linear(in_features=3072, out_features=1024, bias=True)

    (1): BatchNorm1d()
    (2): ReLU()
    (3): Dropout()
    (4): Linear(in_features=1024, out_features=10, bias=True)

  )
  (loss): CrossEntropyLoss()
)
```

- `Dropout` 层的实现按照文档给出，若是 `self.training == True`，则对每个神经元随机 `drop` 之后乘上 $(1-p)$ 进行调整，否则直接返回即可。
- `BatchNorm` 层的实现按照文档和参考文献给出，对 `running_mean` 和 `running_var` 进行记录但不当成模型参数，用于 `inference` 阶段。

1.2 最佳实验结果

最佳实验结果的可改变超参为：

超参	值
dropout_rate	0.5
batch_size	500

超参	值
learning_rate	0.001

最佳实验结果为：

结果	值
training loss	0.608461869508028
training accuracy	**0.7891750365495682**
validation loss	1.4441942930221559
validation accuracy	**0.5550000309944153**
best validation accuracy	0.5629000276327133
final test loss	1.359006679058075
final test accuracy	**0.5610000312328338**

以下结果为最佳实验结果的 `ACC` 和 `Loss` 的图。

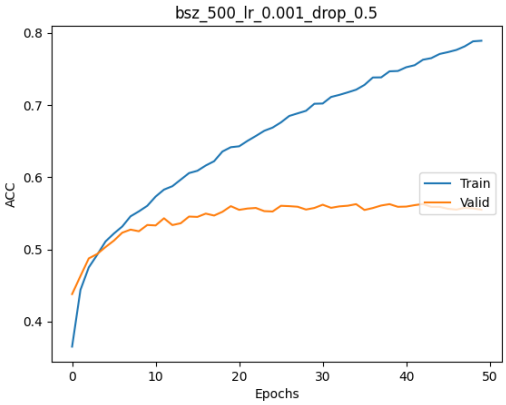

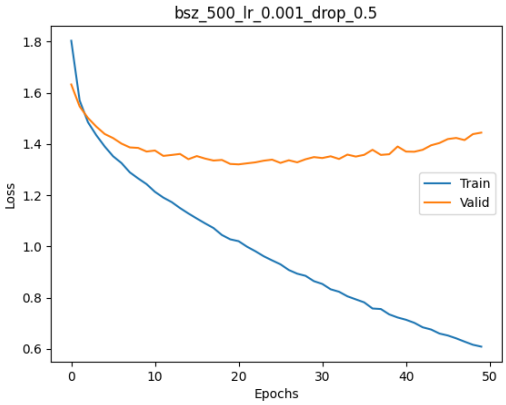

1.3 无 Dropout 实验

我们使用上述实验效果最好的超参进行实验，此外，将模型架构中的 `Dropout` 层去掉（可以通过 `dropout_rate = 0.0` 实现），模型架构为：`input -- Linear - ReLU - Dropout - Linear - loss`，实验结果如下：

结果	值
training loss	0.04587939833290875
training accuracy	**0.9923500388860702**
validation loss	2.2439882874488832
validation accuracy	**0.5269000291824341**
best validation accuracy	0.5409000277519226
final test loss	1.3810120344161987
final test accuracy	**0.5376000240445137**

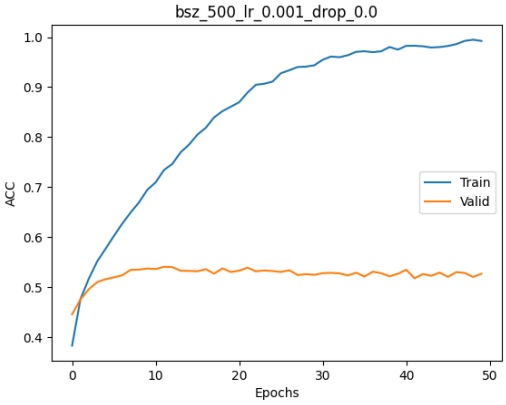

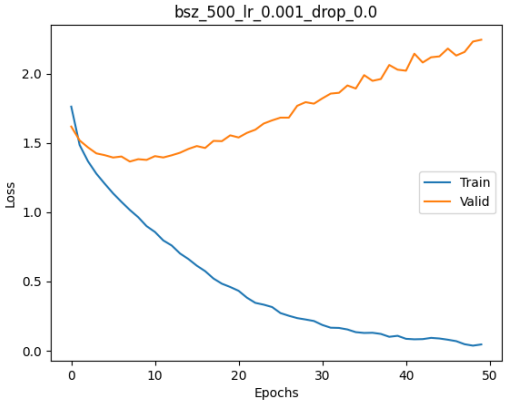

实验结果的分析在后面 ~~

1.4 无 BatchNorm 实验

我们使用上述实验效果最好的超参进行实验。此外，将模型架构中的 `BatchNorm` 层去掉，模型架构为：`input - Linear - BN - ReLU - Dropout - Linear - loss`，实验结果如下：

结果	值
training loss	0.6915876083076
training accuracy	**0.7644750341773033**
validation loss	1.501079499721527
validation accuracy	**0.5545000255107879**
best validation accuracy	0.5635000318288803
final test loss	1.3940251529216767
final test accuracy	**0.5554000198841095**

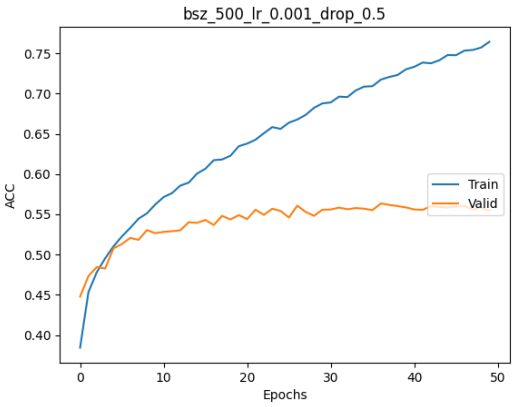

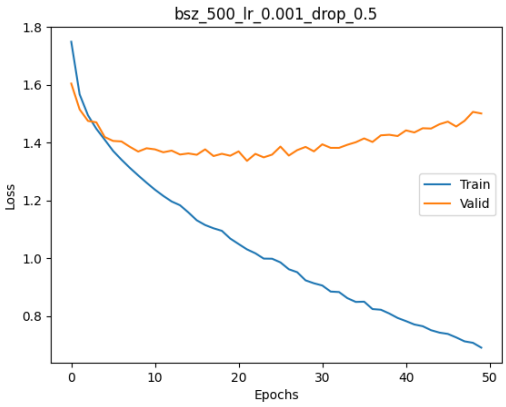

实验结果的分析在后面 ~~

2. CNN

2.1 网络架构

我们采用文档中给出的 `input - Conv - BN - ReLU - Dropout - MaxPool - Conv - BN - ReLU - Dropout - MaxPool - Linear - loss` 的架构进行搭建网络，实验中设置的超参数如下：

```
{
    "dropout_rate": [0.0, 0.1, 0.3, 0.5],          (可改变)
    "batch_size": [50, 100, 200, 500],             (可改变)
    "learning_rate": [0.01, 0.001, 0.0005, 0.0001], (可改变)
    "num_epochs": 50,
    "hidden_channels": (1024, 1024),               (两个 channels 均固定为 1024)
    "kernel_size": (5, 5)                          (两个卷积核 kernel_size 均固定为 5x5)
    "MaxPool2d": {                                 (两个最大池化层固定参数)
        "kernel_size": (2, 2),                     (池化核 2x2)
        "stride": (2, 2)                           (步长为 2)
    }
}
```

我们固定跑 50 个 `epoch`，网络架构如下（其余超参默认）：

```
Model(
  (network): Sequential(
    (0): Conv2d(3, 256, kernel_size=(5, 5), stride=(1, 1))
    (1): BatchNorm2d()
    (2): ReLU()
    (3): Dropout()
    (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (5): Conv2d(256, 256, kernel_size=(5, 5), stride=(1, 1))
    (6): BatchNorm2d()
    (7): ReLU()
    (8): Dropout()
    (9): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (linear): Linear(in_features=6400, out_features=10, bias=True)

  (loss): CrossEntropyLoss()
)
```

- `Dropout` 层的实现按照文档给出，若是 `self.training == True`，则对每个通道随机 `drop` 之后乘上 $(1-p)$ 进行调整，否则直接返回即可。
- `BatchNorm2D` 层的实现按照文档和参考文献给出，对 `running_mean` 和 `running_var` 进行记录但不当成模型参数，用于 `inference` 阶段。

另外，也参考了课件：

Batch Normalization

- Application in CNN
  - There are 3 “feature” dimensions

$$\boldsymbol{x}: N \times C \times H \times W$$

$$\boldsymbol{\mu}, \boldsymbol{\sigma}: 1 \times C \times 1 \times 1$$

$$\boldsymbol{\gamma}, \boldsymbol{\beta}: 1 \times C \times 1 \times 1$$

$$\boldsymbol{y} = \frac{\boldsymbol{\gamma} \odot (\boldsymbol{x} - \boldsymbol{\mu})}{\boldsymbol{\sigma}} + \boldsymbol{\beta}$$

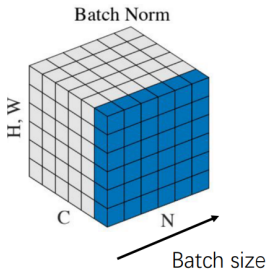

2.2 最佳实验结果

最佳实验结果的可改变超参为：

超参	值
dropout_rate	0.0
batch_size	100
learning_rate	0.001

最佳实验结果为：

结果	值
training loss	0.1002505999733694
training accuracy	**0.9653749735653401**
validation loss	1.233576392531395
validation accuracy	**0.7577999812364579**
best validation accuracy	0.7865999799966812
final test loss	1.1286860883235932
final test accuracy	**0.7769999796152115**

以下结果为最佳实验结果的 `ACC` 和 `Loss` 的图。

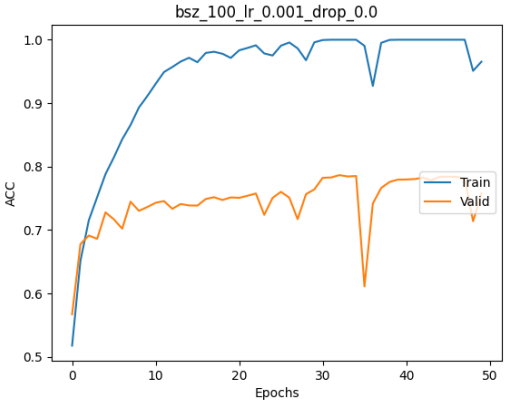

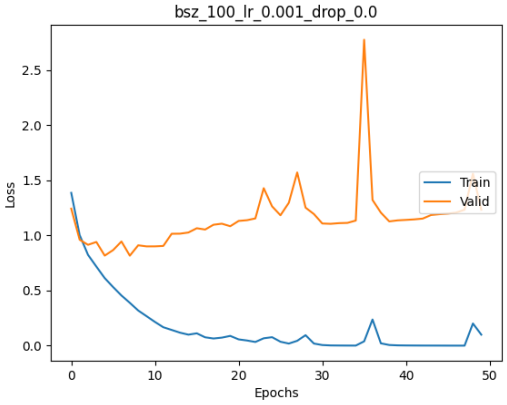

2.3 无 Dropout 实验

我们使用上述实验效果最好的超参进行实验，此外，将模型架构中的 `Dropout` 层去掉（可以通过 `dropout_rate = 0.0` 实现），模型架构为：`input -- Linear - ReLU - Dropout - Linear - loss`，实验结果即为**上述最佳实验结果。**

实验结果的分析在后面 ~~

2.4 无 BatchNorm 实验

我们使用上述实验效果最好的超参进行实验。此外，将模型架构中的 `BatchNorm` 层去掉，模型架构为：`input - Conv - ReLU - Dropout - MaxPool - Conv - ReLU - Dropout - MaxPool - Linear - loss`，实验结果如下：

结果	值
training loss	0.06134577980148606
training accuracy	**0.978524968624115**
validation loss	2.5819300985336304
validation accuracy	**0.6840999847650528**
best validation accuracy	0.717499983906746
final test loss	0.8769321936368942
final test accuracy	**0.7058999854326248**

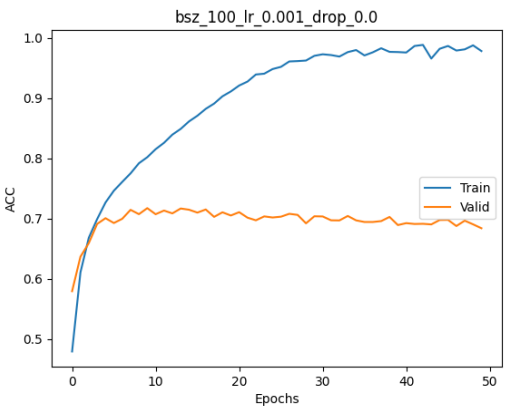

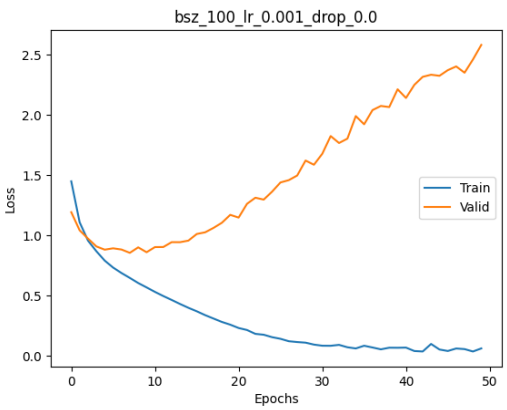

实验结果的分析在后面 ~~

2.5 `Dropout1d` && `Dropout2D`

结果	Dropout2d	Dropout1d
training loss	0.1002505999733694	0.0004943044707033551
training accuracy	**0.9653749735653401**	**1.0**
validation loss	1.233576392531395	1.2217035603523254
validation accuracy	**0.7577999812364579**	**0.7779999768733978**
best validation accuracy	0.7865999799966812	0.7817999798059464
final test loss	1.1286860883235932	1.1444447153806687
final test accuracy	**0.7769999796152115**	**0.7764999788999557**

以下是 `Dropout1d` 的图像：

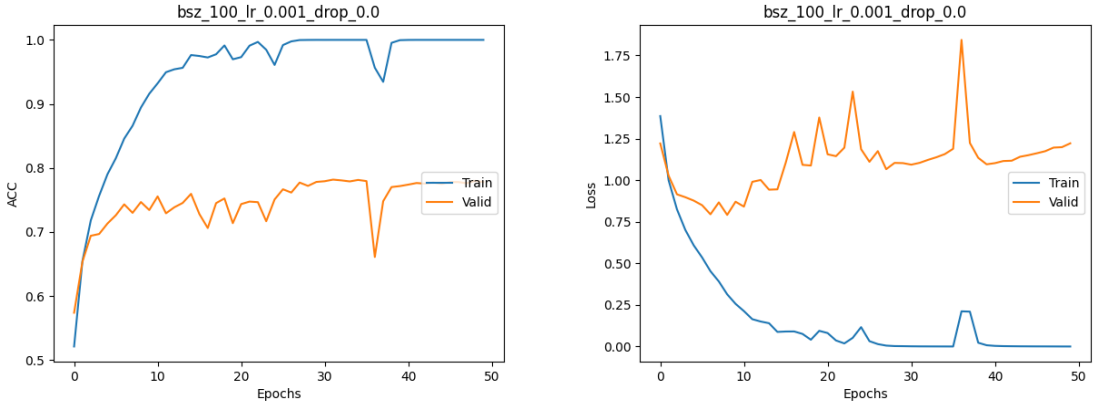

以下是 `Dropout2d` 的图像：

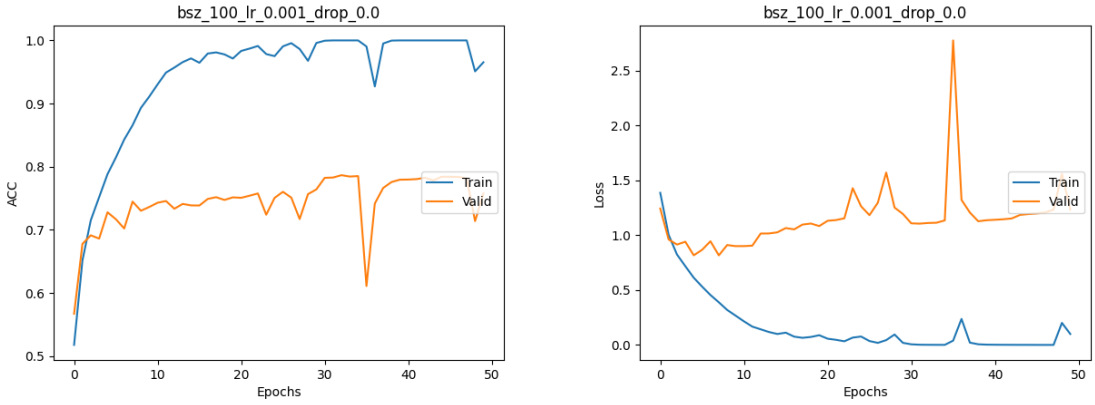

从最终的实验结果可以看出，二者的训练表现并没有太大差别，`Dropout2d` 会略微好于 `Dropout1d`，但是如果从训练的效率上来看，`Dropout1d` 的平均 `epoch` 训练时长大概为 $40s$，但是 `Dropout2d` 的平均 `epoch` 训练时长只需要 $8s$ 左右，可以看出来二者的效率差别是非常大的，更不用说在用到更深的 `CNN` 网络的时候的效率影响了。

因此我们更倾向于在 `CNN` 中使用 `Dropout2d`，将一个通道看成一个整体。事实上，`CNN` 的一个通道可以看成是一个卷积核提取的特征，以特征的粒度来选择是否需要 `drop` 掉，可以理解为 `CNN` 提取了很多的特征，但是有些特征可能有用，有些可能没用，因此 `drop` 掉一整个特征的效率更高也更合理。

3. 实验结果分析

3.1 BatchNorm 的作用

若对原始数据集如果 `shuffle` 得不够均匀，这有可能导致每个 `batch` 的数据分布不均匀，尤其是在 `batch_size` 较小的时候，这种不均匀现象会更加明显，也因此容易导致模型训练过程出现较大的波动。

基于此，`BatchNorm` 的作用就在于将每一层输入的数据进行归一化，得到一个比较相似的分布，都分布到均值为 0 方差为 1 上，但是如果每一层都这样归一化，又容易导致学习到的特征被破坏，因此考虑增加 γ 和 β 这两个可学习的参数进行平移和缩放。

我们从图像上也可以观察出来，有 `BatchNorm` 的一组训练时的抖动较小，收敛也比较快。

3.2 Dropout 的作用

从 `MLP` 的结果对比上可以看出，有 `dropout` 的一组的 `train ACC` 为 78.9%，没有的一组几乎达到 100%，但是从最终在测试集上的效果来看，反而有 `dropout` 的一组效果更好。

可以看出来，`dropout` 的作用主要是防止出现过拟合的情况，当没有 `dropout` 的时候，`train` 和 `valid` 的差别较大，而且在训练 `epoch` 较多的时候，在 `valid` 集上的 `loss` 甚至还会变大，跟 `train` 背道而驰，很明显出现了过拟合的现象。随着 `dropout` 的加入过拟合现象明显缓解，在后面的调参实验中，我们将给出不同的 `dropout_rate` 下模型的表现，当 `dropout_rate` 过高的时候也可能导致模型出现欠拟合的情况。

但是从 `CNN` 的效果上看，貌似 `dropout_rate = 0`，也就是没有 `dropout` 层的时候效果最好。这可能是我们考虑的超参并不多，比如 `CNN` 网络的通道数、卷积核大小以及 `maxpool` 的大小等参数我们都是定死的，于是考虑设置更小的通道数进行实验，比如设置为 128 , 结果发现能得到跟 `MLP` 类似的结论。

4. 思考题

4.1 self.training 的作用

这是 `PyTorch` 深度学习框架提供的一个内置属性，当对模型调用 `model.train()` 方法的时候，该 `model` 的 `training` 属性就会被设置为 `True`，表示正在训练；同理，如果对模型调用 `model.eval()` 方法，该属性就会被设置为 `False`。

对于 `Dropout` 层和 `BatchNorm` 层，其在 `train` 阶段和 `eval` 阶段的行为并不同，因此我们需要通过该属性来判断目前模型是处于哪个阶段，来进行分别处理。

4.2 train_loss 与 valid_loss 的对比

这两个损失分别是在训练集以及验证集上计算而来的，两个数据集并不同。当两者差别较大，而且往往是 `train_loss` 较小而 `valid_loss` 较大的时候，这也就是过拟合的现象，这意味着模型在训练过程中，学习到了训练集上很多特征，但是并不是所有特征都是必要的，这虽然会让模型在训练集表现越来越好，但是当训练集的数据不足以代表更广的数据，比如验证集的数据时，模型的泛化能力就难以增强。

虽然说要学习到足够的特征，但是过于细节的特征学习也许表现并不好，因此这也是一个 `trade-off`，在欠拟合和过拟合之间取得较好的平衡点。我们也从 `Loss` 曲线中可以看出，`train_loss` 基本是一路下滑，但是 `valid_loss` 一般是先下降后上升，因此 `valid_loss` 以及验证集的目的就在于，当发现模型的 `valid_loss` 开始上升时，也就是在转折点处，停止模型的训练，即设置一个 `early_stop` 的阈值，去改善过拟合的问题。

4.3 CNN && MLP 对比

`CNN` 以及 `MLP` 最好的结果在下表呈现：

结果	`CNN`	`MLP`
training loss	0.1002505999733694	0.608461869508028
training accuracy	**0.9653749735653401**	**0.7891750365495682**
validation loss	1.233576392531395	1.4441942930221559

结果	CNN	MLP
validation accuracy	**0.7577999812364579**	**0.5550000309944153**
best validation accuracy	0.7865999799966812	0.5629000276327133
final test loss	1.1286860883235932	1.359006679058075
final test accuracy	**0.7769999796152115**	**0.5610000312328338**

从二者的模型架构来对比，可以发现 CNN 的模型架构更加复杂，每个 epoch 的时间也相对来说更长，但是从最终的表现来看，CNN 要明显优于 MLP。

相较于 MLP，CNN 网络实现了局部连接以及权值共享，训练参数量大大减少，而 MLP 由于较大的参数量更容易产生过拟合的情况。另外，CNN 可以对一个像素块的周围一起进行运算，而不是像 MLP 那样平铺地计算，因此 CNN 可以对图像的空间信息进行更好的模拟，而 MLP 可以看成是卷积核大小为 1 的 CNN，图片中相邻像素块的联系并不如 CNN 那么紧密，因此 CNN 更适合于处理图像信息，更适合于去提取图像中局部的特征。

5. 超参实验

此部分里，我们选取 learning_rate、dropout_rate 以及 batch_size 三者进行超参数实验，探究这些超参数是如何影响 Dropout 和 BatchNorm 层的表现的。

5.1 实验设置

首先，CNN 和 MLP 模型网络均保留 BatchNorm 以及 Dropout 层，对于 MLP 网络，我们的超参设置如下：

```
{
    "dropout_rate": [0.0, 0.1, 0.3, 0.5],          (可改变)
    "batch_size": [50, 100, 200, 500],             (可改变)
    "learning_rate":[0.01, 0.001, 0.0005, 0.0001], (可改变)
    "num_epochs": 50,
    "hidden_size": 1024,
}
```

对于 CNN 网络，我们的超参设置如下：

```
{
    "dropout_rate": [0.0, 0.1, 0.3, 0.5],          (可改变)
    "batch_size": [50, 100, 200, 500],             (可改变)
    "learning_rate":[0.01, 0.001, 0.0005, 0.0001], (可改变)
    "num_epochs": 50,
    "hidden_channels": (1024, 1024),               (两个 channels 均固定为 1024)
    "kernel_size": (5, 5)                          (两个卷积核 kernel_size 均固定为 5x5)
    "MaxPool2d": {                                 (两个最大池化层固定参数)
        "kernel_size": (2, 2),                     (池化核 2x2)
        "stride": (2, 2)                           (步长为 2)
    }
}
```

5.2 实验结果

5.2.1 dropout_rate

在调整 `dropout_rate` 时，我们固定其他可改变的超参为对应的最佳实验结果所设置的超参：

```
{
    "dropout_rate": [0.0, 0.1, 0.3, 0.5],
    "batch_size": {
        "MLP": 500,
        "CNN": 100,
    },
    "learning_rate": {
        "MLP": 0.001,
        "CNN": 0.001,
    }
}
```

我们首先汇报在这四种 `dropout_rate` 下的实验结果，再进行结果分析。

5.2.1.1 `MLP`

dropout_rate	0.0	0.1	0.3	0.5
training loss	0.0459	0.1498	0.3399	0.6085
training accuracy	**0.9924**	**0.9565**	**0.8868**	**0.7892**
validation loss	2.244	1.9759	1.708	1.444
validation accuracy	**0.5269**	**0.5312**	**0.5362**	**0.5550**
best validation accuracy	0.5409	0.5496	0.5577	0.5629
final test loss	1.381	1.464	1.357	1.359
final test accuracy	**0.5376**	**0.5432**	**0.5517**	**0.5610**

在训练集和验证集上的 `Accuracy` 和 `Loss` 如下：

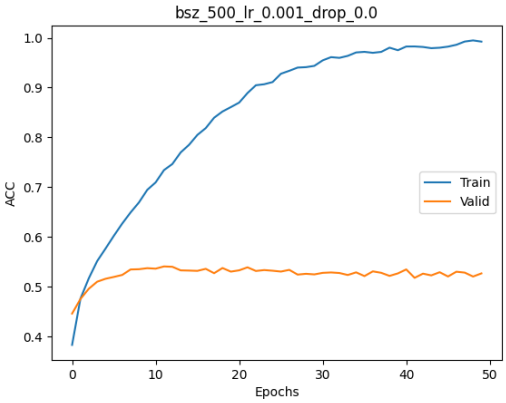

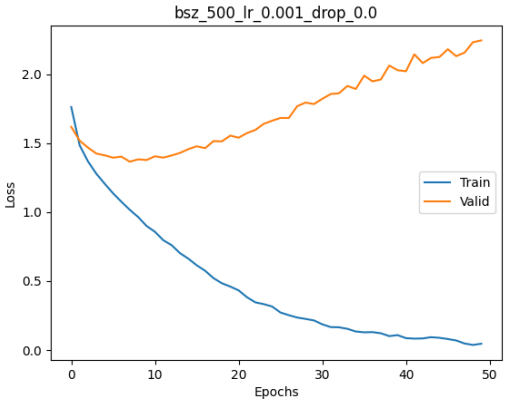

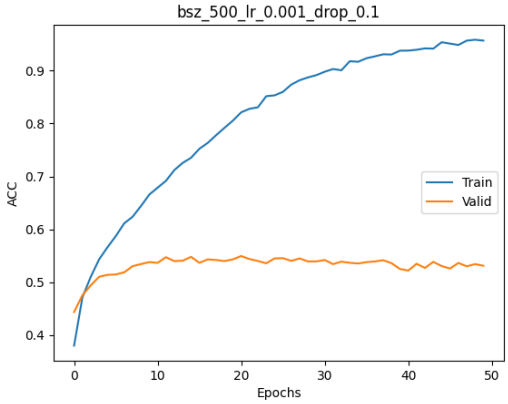

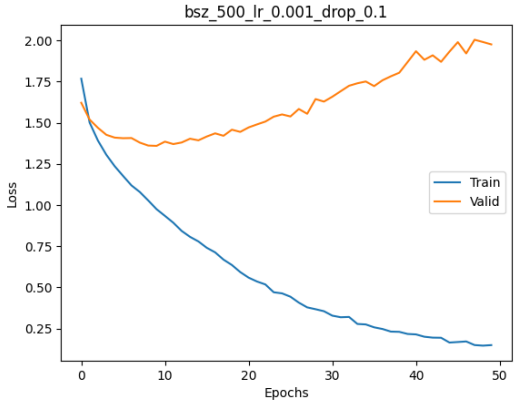

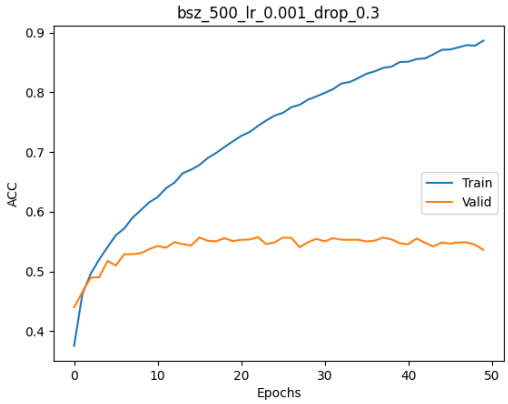

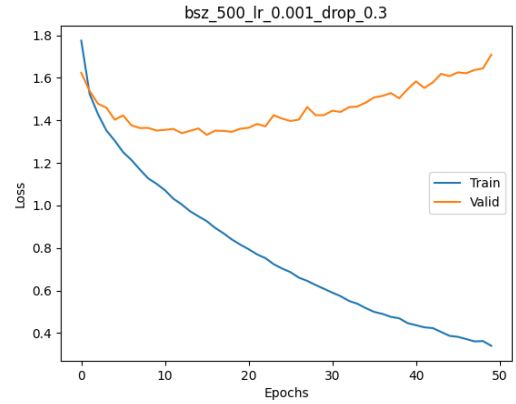

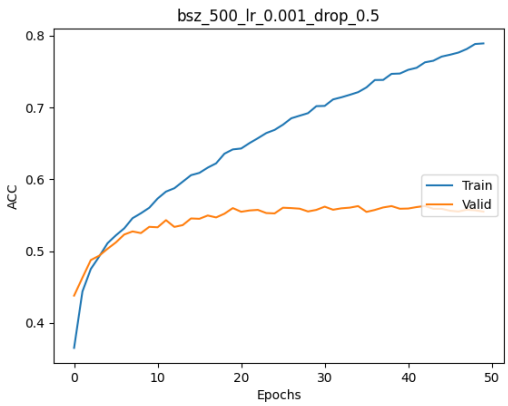

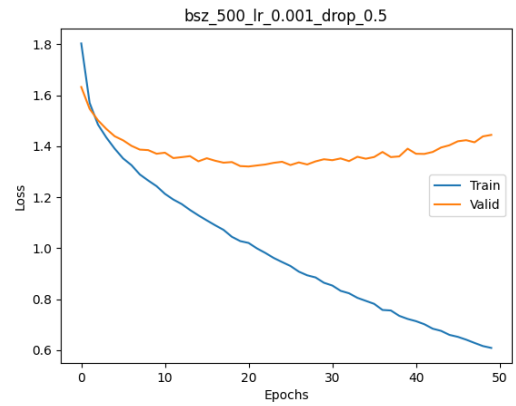

5.2.1.2 CNN

dropout_rate	0.0	0.1	0.3	0.5
training loss	0.1003	0.0468	0.1496	0.4503
training accuracy	**0.9654**	**0.9850**	**0.9493**	**0.8447**
validation loss	1.234	1.306	0.9274	0.7266
validation accuracy	**0.7578**	**0.7437**	**0.7495**	**0.7594**
best validation accuracy	0.7866	0.7547	0.7640	0.7657
final test loss	1.129	0.9356	0.7470	0.7335
final test accuracy	**0.7770**	**0.7537**	**0.7542**	**0.7578**

在训练集和验证集上的 `Accuracy` 和 `Loss` 如下：

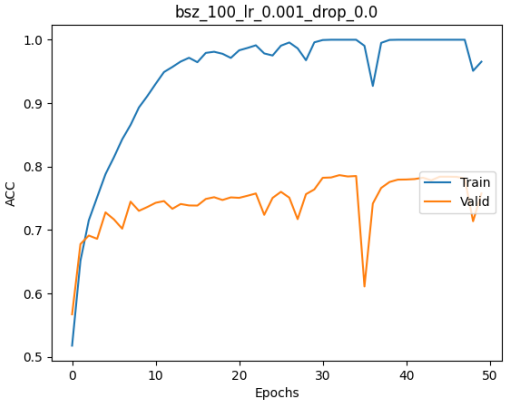

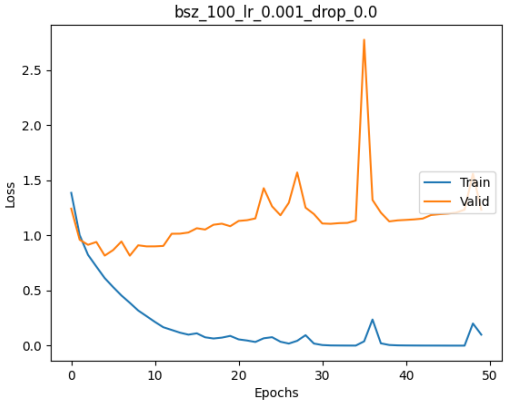

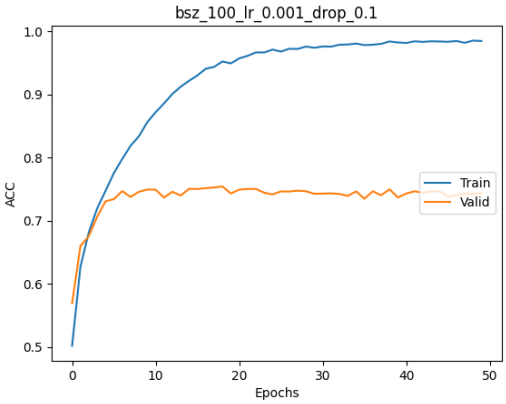

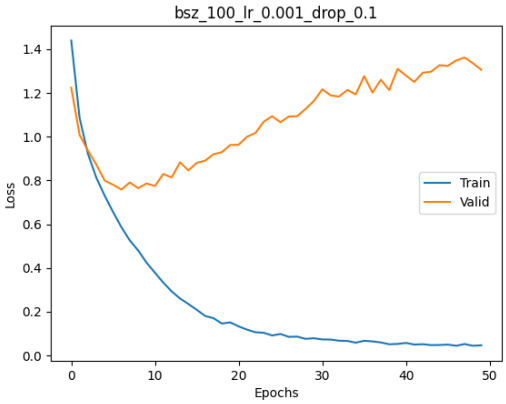

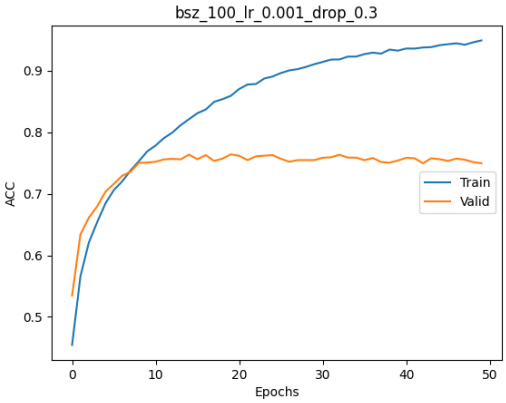

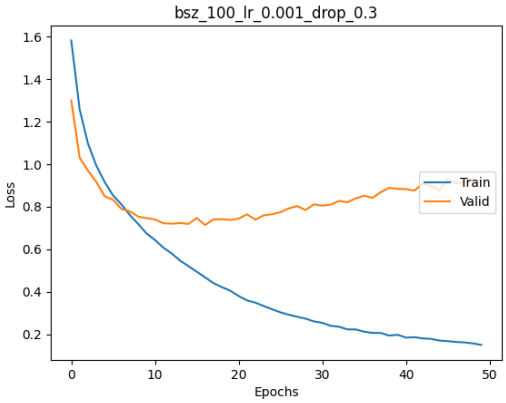

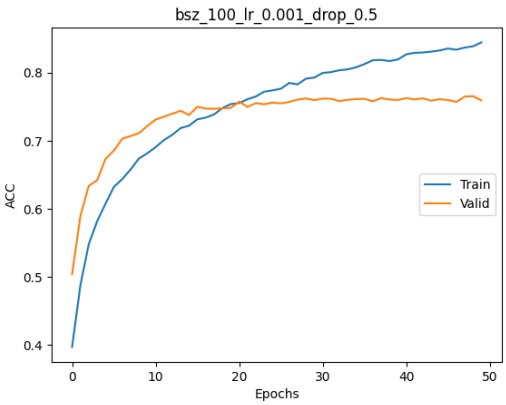

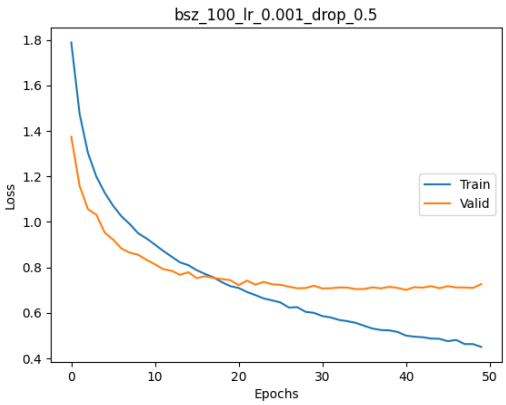

5.2.1.3 结果分析

对于 `MLP`，随着 `dropout_rate` 的提高，最后一次训练的 `ACC` 逐渐下降靠近验证集的 `ACC`。一开始没有 `dropout` 时，训练集上的准确率接近 100% 而验证集只有 50% 左右，到所测试的最高的 `dropout_rate = 0.5` 时，训练集上的准确率为 78% 而验证集上为 55% 左右，很明显看到过拟合的情况有不少缓解。另一方面，我们也可以从图像中看出，随着 `dropout_rate` 的提高，`valid_loss` 曲线的转折点往较大的 `epoch` 处

偏移，即说明过拟合情况正在缓解，并且 `valid_loss` 没有反向上升太多。

对于 `CNN`，随着 `dropout_rate` 的提高，训练集上的准确率也逐步向验证集靠拢，并且从曲线中可以看出，在 `CNN` 里，随着 `dropout_rate` 的提高，模型训练的稳定性也提升了，原因可能是调整 `dropout_rate` 时，相当于同时训练了很多个模型，在 `dropout_rate = 0.5` 时，随机 `drop` 的通道数最平均，此时的排列组合方式是最多的，因此相当于是很多的模型平均的效果，使得最后的稳定性有所提升。

从实验结果我们也注意到，其实 `dropout_rate` 的超参实验的参数设置可以更广一些，比如设置 `dropout_rate = 0.7`，因为 `MLP` 和 `CNN` 都只是缓解了过拟合现象，而没有达到一个居中的效果，或者有欠拟合的情况，但是从理论分析上可知，`dropout_rate` 较高时，确实会出现欠拟合的现象，因此我们也测试了 0.7 的情况，发现二者均出现了训练集准确率低于验证集准确率的情况。

5.2.2 batch_size

在调整 `batch_size` 时，我们固定其他可改变的超参为对应的最佳实验结果所设置的超参：

```
{
    "batch_size": [50, 100, 200, 500],
    "dropout_rate": {
        "MLP": 0.5,
        "CNN": 0.0,
    }
    "learning_rate": {
        "MLP": 0.001,
        "CNN": 0.001,
    }
}
```

我们首先汇报在这四种 `batch_size` 下的实验结果，再进行结果分析。

5.2.2.1 `MLP`

batch_size	50	100	200	500
training loss	0.4680	0.4992	0.5452	0.6085
training accuracy	**0.8320**	**0.8219**	**0.8098**	**0.7892**
validation loss	2.084	1.669	1.520	1.444
validation accuracy	**0.5162**	**0.5451**	**0.5555**	**0.5550**
best validation accuracy	0.5573	0.5582	0.5648	0.5629
final test loss	1.399	1.373	1.435	1.359
final test accuracy	**0.5513**	**0.5547**	**0.5606**	**0.5610**

在训练集和验证集上的 `Accuracy` 和 `Loss` 如下：

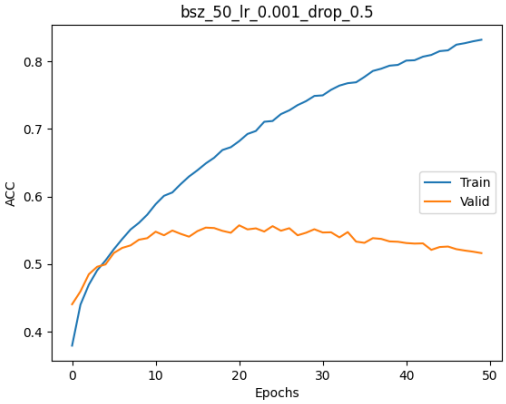

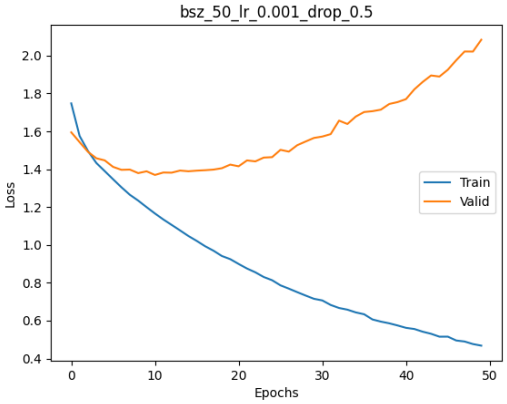

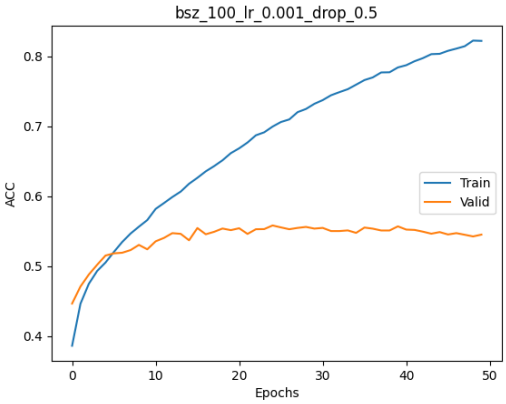

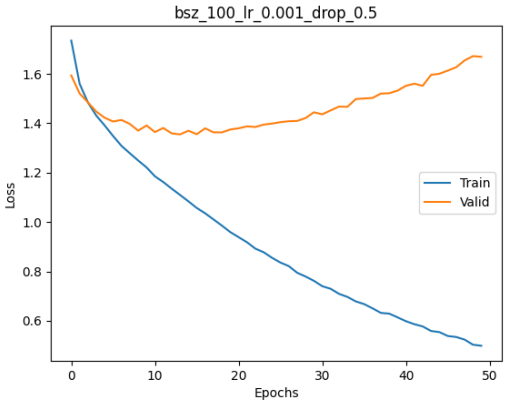

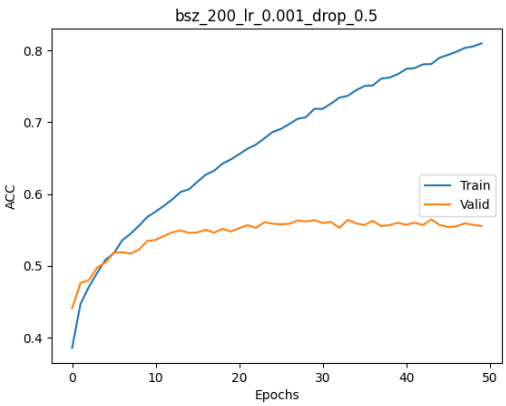

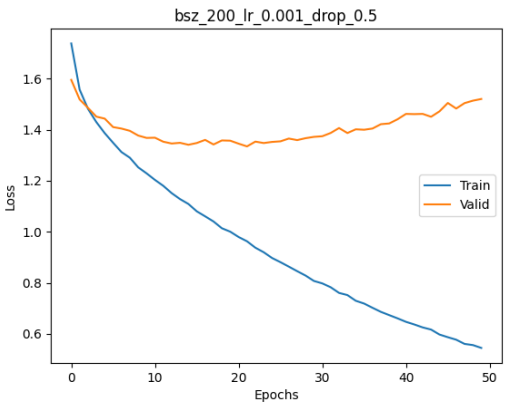

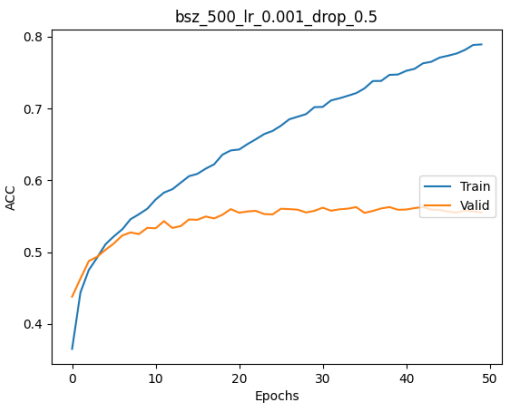

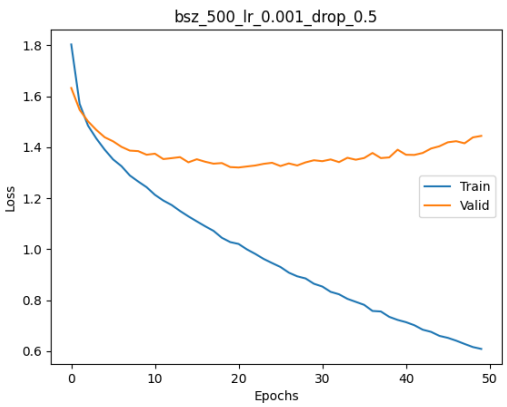

5.2.2.2 CNN

batch_size	50	100	200	500
training loss	0.0144	0.1003	0.0005	0.0007

batch_size	50	100	200	500
training accuracy	**0.9956**	**0.9654**	**1.0**	**1.0**
validation loss	1.681	1.234	1.105	1.001
validation accuracy	**0.7483**	**0.7578**	**0.7848**	**0.7803**
best validation accuracy	0.7645	0.7866	0.7848	0.7849
final test loss	1.375	1.129	1.078	0.9452
final test accuracy	**0.7549**	**0.7770**	**0.7747**	**0.7766**

在训练集和验证集上的 `Accuracy` 和 `Loss` 如下：

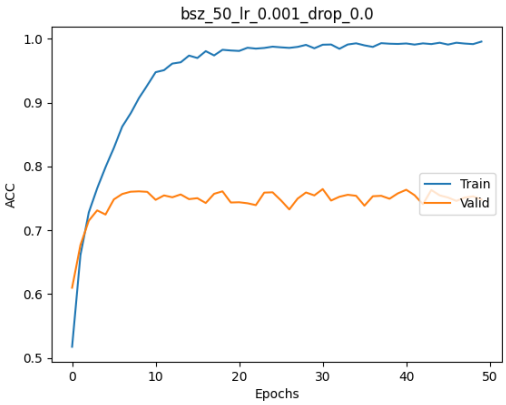

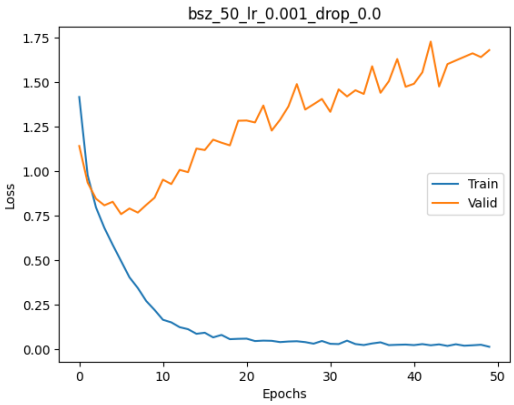

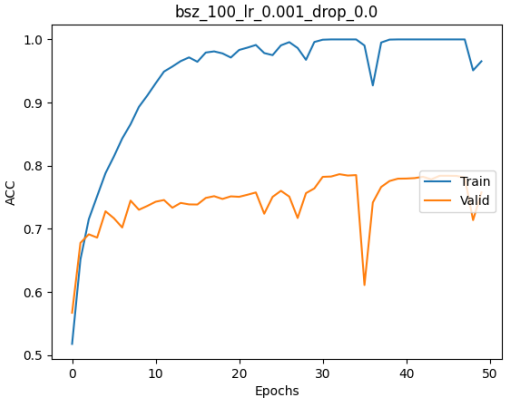

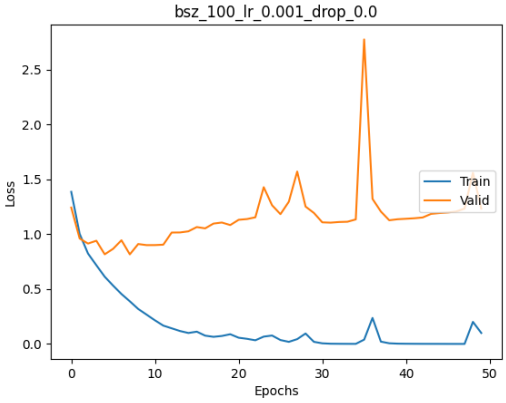

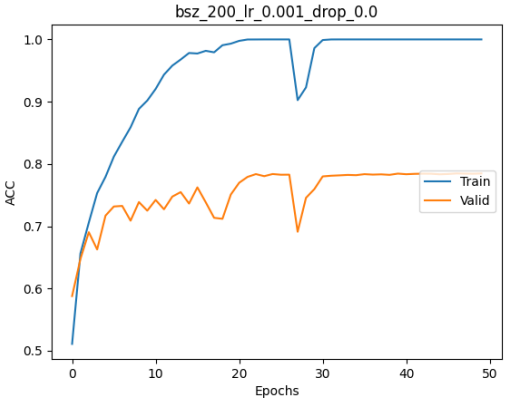

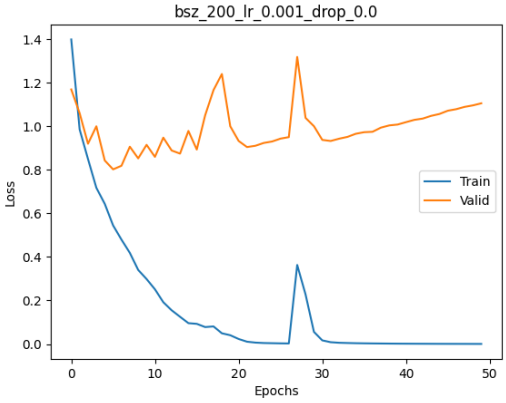

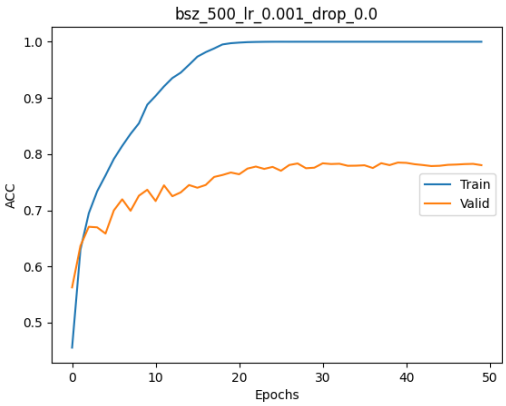

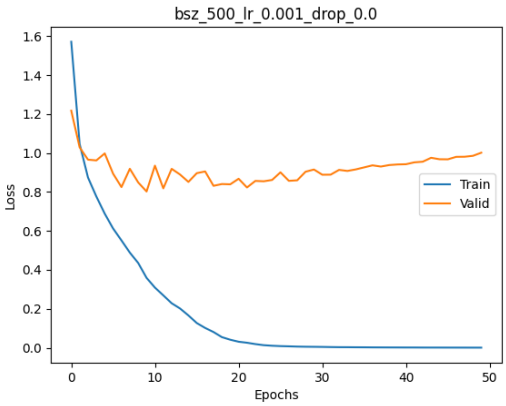

5.2.2.3 结果分析

随着 `batch_size` 的增大，`MLP` 和 `CNN` 的表现均有略微提升，虽然 `CNN` 在 100 的时候表现最好，但是 200 和 500 下的测试集准确率与之不相上下，在误差允许范围内。对于 `MLP`，可以看得出来 `batch_size` 的提升使得模型的过拟合程度有所降低，而对于 `CNN`，从图像上可以看出 50 个 `epoch` 对于 `CNN` 有些过多了，应该差不多 30 个 `epoch` 就足够了，从图像中也可以看出 `valid_loss` 的反向上升现象有所减缓。（另外对于 `batch_size=100` 的一组在训练集上的准确率可能不太具有代表性，从图像中可以看出这是遇到了一些特殊情况，50 个 `epoch` 正好处于尖峰的位置，也说明了模型稳定性还不是很好）

另一方面，从图像上也可以看出来随着 `batch_size` 的提高，`BatchNorm` 对于增强模型的训练稳定性的能力更强。事实上 `BatchNorm` 本意就在于对一个 `batch` 的数据进行归一化，减小不同 `batch` 之间的偏差。如果一个 `batch` 过小，这样的归一化往往不能正确反映数据集的特征，会导致一些误差，使得模型训练过程的波动较大。因此对于 `BatchNorm` 的效果，我们可以适当提高 `batch_size`。

5.2.3 learning_rate

在调整 `learning_rate` 时，我们固定其他可改变的超参为对应的最佳实验结果所设置的超参：

```
{
    "learning_rate": [0.01, 0.001, 0.0005, 0.0001],
    "dropout_rate": {
        "MLP": 0.5,
        "CNN": 0.0,
    }
    "batch_size": {
        "MLP": 500,
        "CNN": 100,
    }
}
```

我们首先汇报在这四种 `learning_rate` 下的实验结果，再进行结果分析。

5.2.3.1 `MLP`

learning_rate	**0.01**	**0.001**	**0.0005**	**0.0001**
training loss	0.5448	0.6085	0.6746	0.7926
training accuracy	**0.8030**	**0.7892**	**0.7679**	**0.7363**
validation loss	1.791	1.444	1.372	1.305
validation accuracy	**0.5284**	**0.5550**	**0.5574**	**0.5569**
best validation accuracy	0.5452	0.5629	0.5626	0.5604

learning_rate	0.01	0.001	0.0005	0.0001
final test loss	1.669	1.359	1.317	1.299
final test accuracy	**0.5451**	**0.5610**	**0.5561**	**0.5539**

在训练集和验证集上的 `Accuracy` 和 `Loss` 如下：

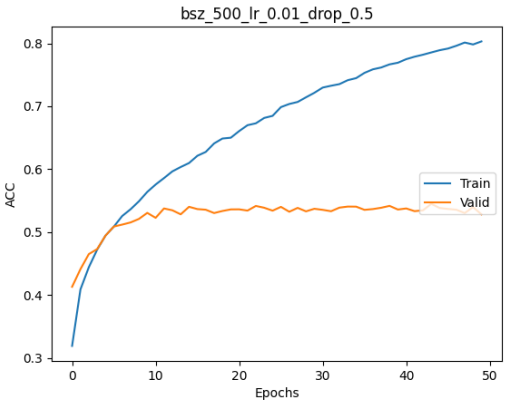

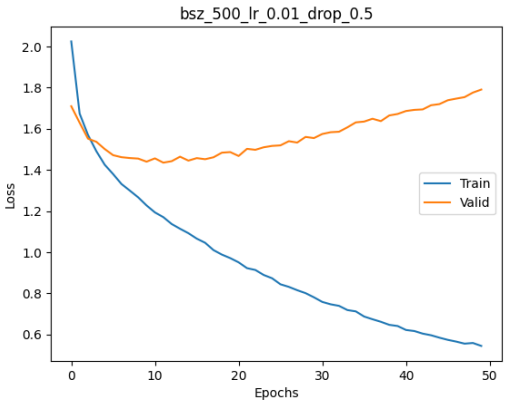

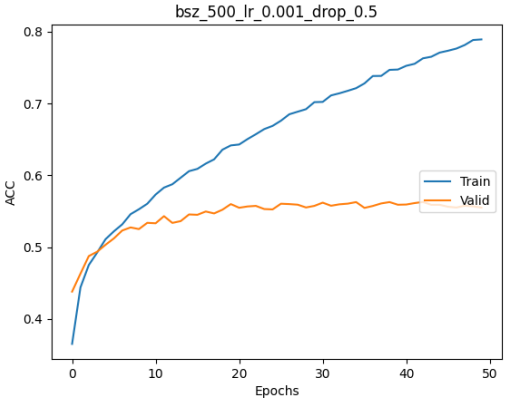

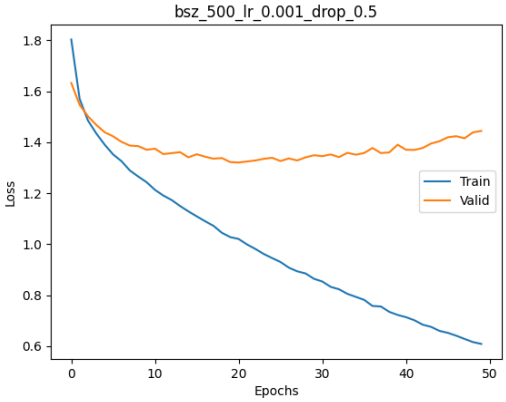

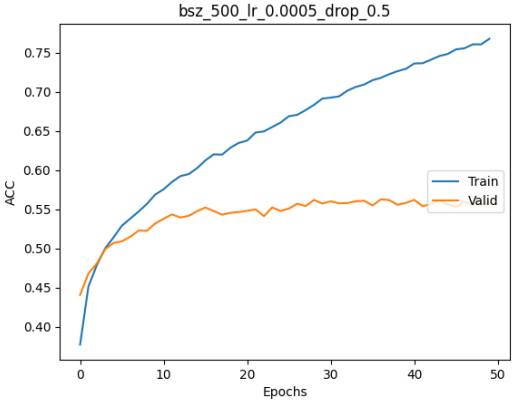

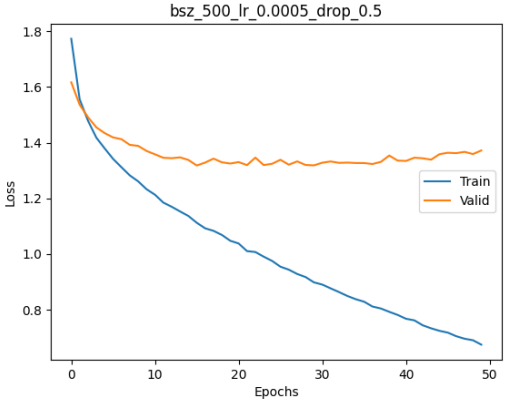

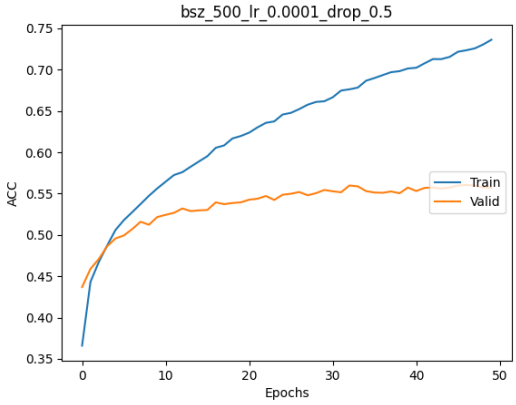

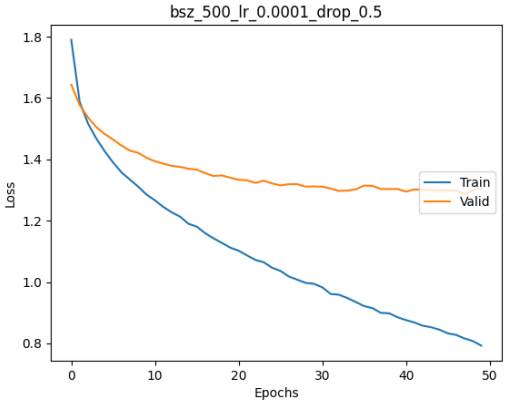

5.2.3.2 CNN

learning_rate	0.01	0.001	0.0005	0.0001
training loss	0.0947	0.1003	0.0067	0.0229
training accuracy	**0.9777**	**0.9654**	**0.9998**	**0.9981**
validation loss	3.976	1.234	1.045	0.9579
validation accuracy	**0.7083**	**0.7578**	**0.7797**	**0.7518**
best validation accuracy	0.7244	0.7866	0.7896	0.7615
final test loss	0.8922	1.129	1.006	0.9667
final test accuracy	**0.7223**	**0.7770**	**0.7722**	**0.7514**

在训练集和验证集上的 `Accuracy` 和 `Loss` 如下：

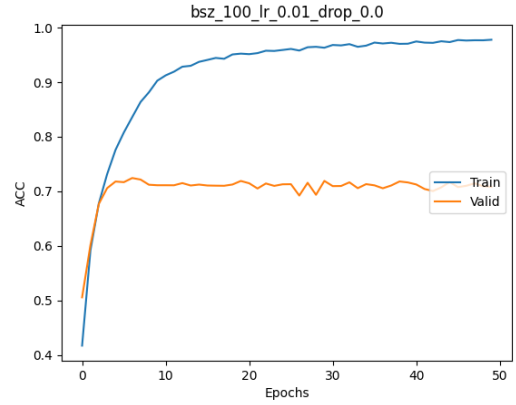

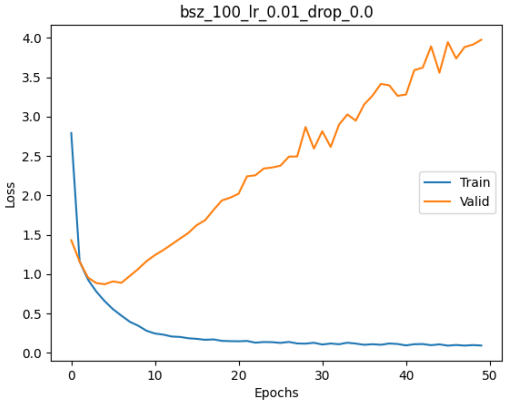

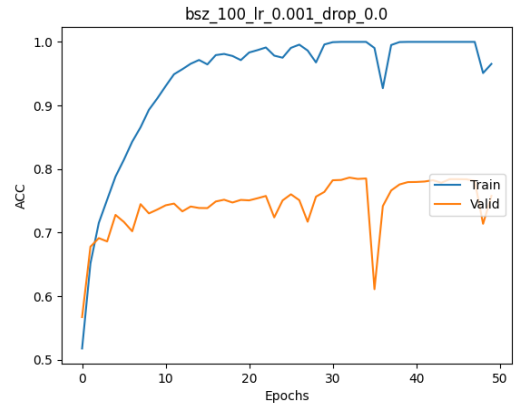

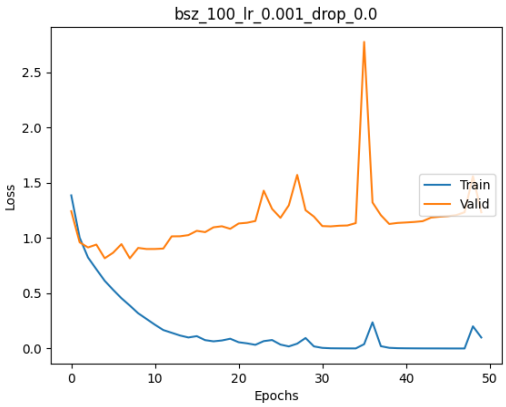

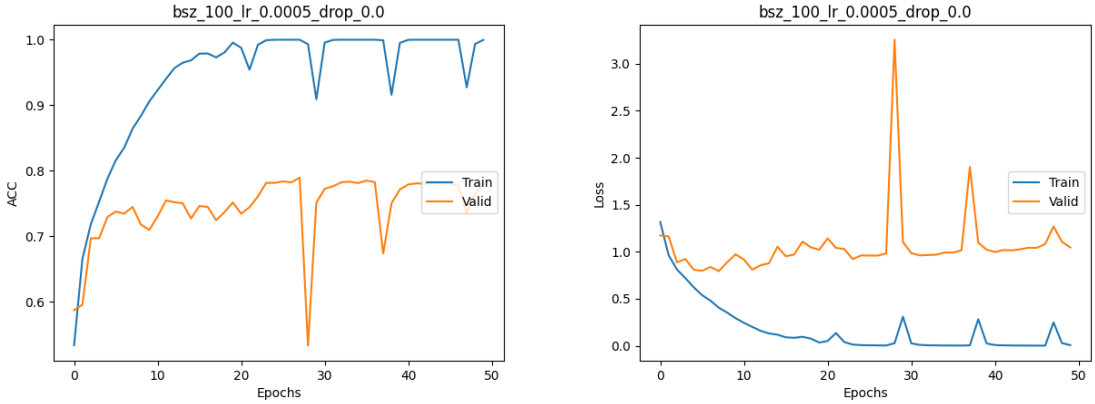

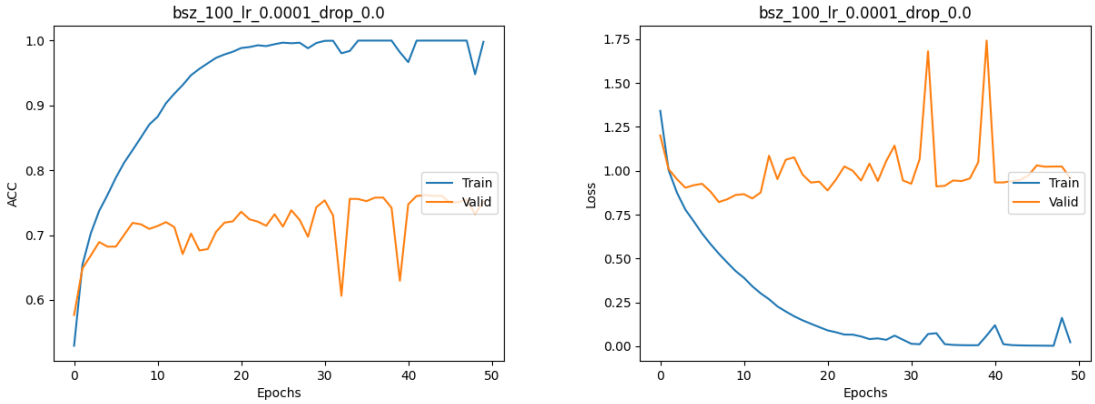

5.2.3.3 结果分析

对于 `MLP` 和 `CNN` 而言，较大的学习率虽然能够使得模型训练较快，`Loss` 能很快降下来，但是从图像中可以看出来，验证集上的损失有反向上升的趋势，`MLP` 比 `CNN` 的图像更明显，即 `valid_loss` 的低谷对应的 `epoch` 数随着 `lr` 的增大而减小，这也说明在训练 `epoch` 数与学习率之间存在一个 `trade-off`，如果设置的不好，就容易产生过拟合现象或者欠拟合现象。

同时对于两个网络而言，都是学习率居中的时候在测试集上表现效果最好。当学习率较高的时候，模型容易出现反复横跳的波动情况，难以收敛，当学习率较低的时候，模型容易陷在局部最优解里，无法搜索到全局最优解。

6. 总结

Lab2 实验给了我一个使用 `PyTorch` 深度学习框架自己搭建网络的机会，让我了解了常用的一些属性和方法，比如 `self.training` 以及 `self.register_buffer` 等之前自己未注意到的部分。另外通过手写 `Dropout` 和 `BatchNorm`，我也对这两种神经网络中的技巧以及作用有了更深的认识。

最后，感谢助教和老师提供的清晰的代码框架以及实验指导文档，这次实验让我收获很多！